Classificação de Violência Comunitária com Aprendizado de Máquina

Classification of Community Violence Using Machine Learning

Bruno Henrique de Souza[1]

[1]Pontifícia Universidade Católica de Goiás.

Março de 2026

Resumo. Este trabalho explora a aplicação de diferentes modelos de aprendizado de máquina combinados com métodos de redução de dimensionalidade para classificar comunidades pelo seu grau de violência (moderada ou grave), com base em características sociais, demográficas e econômicas. Os modelos avaliados foram *Gradient Boosting* (GB), *Random Forest* (RF) e *Support Vector Machine* (SVM), aplicados em conjunto com *Principal Component Analysis* (PCA) e *Linear Discriminant Analysis* (LDA). Os modelos foram avaliados por meio de validação cruzada (CV) estratificada e testados em um conjunto separado, utilizando precisão, *recall* e *F1-macro* como métricas. Os resultados indicam que a redução de dimensionalidade não trouxe ganho de desempenho para este conjunto de dados, sendo o *Random Forest* sem redução de dimensionalidade a configuração mais eficaz, com precisão de 0,866, recall de 0,856 e F1-macro de 0,852 no conjunto de teste.

Palavras-chave: Aprendizado de máquina, redução de dimensionalidade, violência comunitária.

Abstract. This work explores the application of different machine learning models combined with dimensionality reduction methods to classify communities by their level of violence (moderate or severe), based on social, demographic, and economic characteristics. The evaluated models were *Gradient Boosting* (GB), *Random Forest* (RF), and *Support Vector Machine* (SVM), applied together with *Principal Component Analysis* (PCA) and *Linear Discriminant Analysis* (LDA). The models were evaluated through stratified cross-validation (CV) and tested on a separate set, using precision, recall, and F1-macro as metrics. The results indicate that dimensionality reduction did not bring performance gains for this dataset, with *Random Forest* without dimensionality reduction being the most effective configuration, achieving precision of 0.866, recall of 0.856, and F1-macro of 0.852 on the test set.

Keywords: Machine learning, dimensionality reduction, community violence.

1 Introdução

Na atualidade a violência urbana é um dos principais desafios da sociedade, tendo impacto direto na qualidade de vida da população e impondo custos consideráveis aos sistemas de segurança pública (JAITMAN et al., 2017; MINAYO, 2006). Considerando esse contexto, conseguir identificar padrões que indicam a predisposição de uma comunidade a índices maiores de violência representa uma contribuição relevante tanto para a formulação de políticas públicas quanto para a alocação eficiente de recursos de segurança (WEISBURD, 2015).

Comumente utilizado para a análise de fenômenos sociais como o investigado neste trabalho, pois essa abordagem permite extrair relações não lineares entre as variáveis socioeconômicas e os indicadores de violência (KYRIAZOS; POGA, 2024). Modelos como *Random Forest*, *Gradient Boosting* e *Support Vector Machine* são reconhecidos pelo desempenho competitivo em classificação com dados tabulares de alta dimensionalidade (KUSHWAHA; KUDALE, 2025).

Este trabalho investiga o impacto de técnicas de redução de dimensionalidade, *Principal Component Analysis* (PCA) e *Linear Discriminant Analysis* (LDA), sobre o desempenho desses classificadores na tarefa de distinguir comunidades com violência moderada ou grave, utilizando o *dataset Communities and Crime Unnormalized* (REDMOND, 2009), composto por aproximadamente 125 variáveis demográficas, econômicas, habitacionais e de estrutura familiar. Desta forma, o presente trabalho tem como objetivo avaliar o impacto da aplicação de PCA e LDA sobre o desempenho dos classificadores Random Forest, Gradient Boosting e Support Vector Machine na tarefa de classificação binária do nível de violência comunitária, identificando a configuração de maior eficácia preditiva.

O presente artigo está organizado da seguinte forma: a Seção 2 descreve os materiais e métodos empregados; a Seção 3 apresenta os resultados e a discussão; e a Seção 4 sintetiza as conclusões e recomendações.

2 Materiais e Métodos

2.1 Conjunto de Dados

O conjunto de dados utilizado foi o *dataset Communities and Crime Unnormalized* (REDMOND, 2009), disponibilizado pela *University of California, Irvine* (UC Irvine) em seu repositório de aprendizado de máquina. O *dataset* é composto por 2215 instâncias e 147 variáveis, sendo 125 preditoras, 4 identificadoras e 18 potenciais variáveis alvo. As instâncias descrevem comunidades norte-americanas sob aspectos demográficos, econômicos, habitacionais e de estrutura familiar, sintetizadas a partir de três fontes distintas: o Censo dos Estados Unidos de 1990, o Law Enforcement Management and Admin Stats (LEMAS) de 1990 e os dados de criminalidade do FBI (Uniform Crime Reports) de 1995.

Para viabilizar a tarefa de classificação binária, a variável alvo contínua *ViolentCrimesPerPop* foi convertida em uma variável binária com base na média de sua distribuição (583,7 crimes violentos por 100 mil habitantes). Comunidades com valor acima desse limiar foram classificadas como de violência grave (classe 1) e as demais como de violência moderada (classe 0). A escolha da média como ponto de corte é justificada pela assimetria positiva da distribuição original, com mediana de 374,1 e desvio padrão de 614,8, que reflete a concentração de comunidades com baixa criminalidade e a existência de casos extremos com taxas muito elevadas (WEISBURD, 2015). O uso da média como limiar, em vez da mediana, posiciona o ponto de corte acima do centro da distribuição, resultando em uma proporção de aproximadamente 66% para a classe 0 (violência moderada) e 34% para a classe 1 (violência grave). Esse desbalanceamento moderado foi tratado nos classificadores por meio do parâmetro Peso das classes definido como balanceada, que ajusta os pesos de cada classe inversamente proporcional à sua frequência.

Na avaliação da qualidade dos dados, o principal desafio encontrado foi a falta significativa de dados para as variáveis originárias do levantamento LEMAS, que registram 1.872 dados faltantes (84,5% das instâncias em cada variável) (REDMOND, 2009). Por ultrapassarem o limiar de 80% de ausência adotado como critério de corte, essas 23 variáveis foram removidas do conjunto preditivo por apresentarem informação insuficiente para imputação confiável (GARCÍA-LAENCINA; SANCHO-GÓMEZ; FIGUEIRAS-VIDAL, 2010). Adicionalmente, 18 variáveis diretamente relacionadas a contagens criminais foram excluídas para evitar vazamento de dados, garantindo que o modelo aprendesse exclusivamente a partir de características estruturais da comunidade. As variáveis restantes com valores faltantes pontuais foram tratadas por imputação pela mediana dentro do *pipeline* de treinamento, estratégia robusta à assimetria das distribuições (GARCÍA-LAENCINA; SANCHO-GÓMEZ; FIGUEIRAS-VIDAL, 2010), garantindo que o imputador fosse ajustado exclusivamente sobre o conjunto de treino.

2.2 Modelos de Classificação

Três algoritmos de aprendizado de máquina supervisionado foram avaliados neste trabalho, selecionados por sua já reconhe-

cida eficiência em tarefas de classificação com dados tabulares de alta dimensionalidade (KUSHWAHA; KUDALE, 2025). O *Support Vector Machine* (SVM) com kernel RBF busca o hiperplano de margem máxima que separa as classes no espaço de características transformado (CORTES; VAPNIK, 1995), configurado com parâmetros:

Parâmetro	**valor**
C	1
γ	automático
Peso das classes	balanceada

O *Random Forest* (RF) combina múltiplas árvores de decisão treinadas sobre subamostras aleatórias dos dados, determinando a predição final por votação majoritária (BREIMAN, 2001), com os parâmetros:

Parâmetro	**valor**
Número de árvores	300
Profundidade máxima	10
Número mínimo/folha	5
Peso das classes	balanceada

O *Gradient Boosting* (GB) constrói árvores sequencialmente, em que cada árvore corrige os erros residuais da anterior por meio de descida do gradiente no espaço funcional (FRIEDMAN, 2001), configurado com os parâmetros:

Parâmetro	**Valor**
Número de árvores	300
Taxa de aprendizado	0,1
Taxa de subamostragem	0,7

Todos os métodos também possuem `random_state` fixado em 42.[1]

2.3 Métodos de Redução de Dimensionalidade

Duas técnicas de redução de dimensionalidade foram integradas aos *pipelines* com o objetivo de investigar seu impacto sobre o desempenho dos classificadores. O *Principal Component Analysis* (PCA) é um método não supervisionado que projeta os dados nas direções de maior variância (JOLLIFFE, 2002), avaliado em duas configurações:

- **PCA-95%:** retenção dos componentes que explicam 95% da variância total;
- **PCA-50:** fixação em 50 componentes.

O *Linear Discriminant Analysis* (LDA) é um método supervisionado que maximiza a separabilidade entre classes por meio de projeções lineares, produzindo uma única componente no caso binário (HASTIE et al., 2009). Adicionalmente, foi avaliada uma configuração *Baseline*, sem redução de dimensionalidade, utilizada como referência para comparação.

Todos os modelos e técnicas foram implementados por meio da biblioteca scikit-learn (PEDREGOSA et al., 2011).

2.4 Modelos de Avaliação

Os modelos foram avaliados por meio de três métricas quantitativas: precisão (*precision*), *recall* e F1-macro. A precisão mede a proporção de predições positivas que são efetivamente corretas, enquanto o *recall* mede

[1] O parâmetro `random_state=42` foi definido em todos os modelos e técnicas para garantir a reprodutibilidade dos experimentos.

a proporção de instâncias positivas corretamente identificadas pelo modelo (SOKOLOVA; LAPALME, 2009). O F1-macro corresponde à média não ponderada do F1-*score* de cada classe, sendo adequado para cenários com desbalanceamento entre classes, pois trata igualmente o desempenho em ambas as classes independentemente de sua frequência (SOKOLOVA; LAPALME, 2009). A acurácia também é reportada como métrica auxiliar de referência.

A avaliação foi conduzida em duas etapas complementares. Na primeira, utilizou-se validação cruzada estratificada com $k = 5$ *folds* sobre o conjunto de treino, garantindo que a proporção entre as classes fosse preservada em cada partição (KOHAVI et al., 1995). Na segunda etapa, os modelos foram treinados novamente sobre o conjunto de treino completo e avaliados em um conjunto de teste separado, correspondente a 20% das instâncias, estratificado e mantido isolado durante todo o processo de desenvolvimento.

3 Resultados e Discussão

Esta seção apresenta os resultados obtidos para cada uma das 12 configurações avaliadas, combinações entre os três classificadores (SVM, RF e GB) e as quatro variantes de pré-processamento (Baseline, PCA-95%, PCA-50 e LDA), seguida de uma comparação global no conjunto de teste.

3.1 Support Vector Machine (SVM)

As Tabelas 1 e 2 apresentam os resultados do SVM com kernel RBF nas quatro configurações de pré-processamento. Na validação cruzada, a configuração Baseline obteve o melhor F1-macro (0,834), seguida de LDA (0,830), PCA-50 (0,824) e PCA-95% (0,813). No conjunto de teste, o Baseline também se destacou com F1-macro de 0,837, acurácia de 0,848, precisão de 0,829 e *recall* de 0,851.

Config.	**Acc**	**F1**	**Prec**	**Rec**
Baseline	**0,845**	**0,834**	**0,827**	**0,845**
PCA-95%	0,828	0,813	0,808	0,820
PCA-50	0,837	0,824	0,817	0,833
LDA	0,842	0,830	0,823	0,842

Tabela 1 – SVM Validação Cruzada

Config.	**Acc**	**F1**	**Prec**	**Rec**
Baseline	0,848	**0,837**	0,829	**0,851**
PCA-95%	0,837	0,824	0,818	0,834
PCA-50	0,845	0,834	0,827	0,849
LDA	**0,850**	**0,837**	**0,831**	0,846

Tabela 2 – SVM Teste

A matriz de confusão do SVM Baseline no conjunto de teste (Tabela 3) evidencia que o modelo classifica corretamente 211 comunidades de violência moderada e 112 de violência grave, com 40 falsos positivos e 18 falsos negativos. O *recall* elevado para a classe grave indica boa sensibilidade do modelo na detecção dos casos de maior risco, comportamento desejável em aplicações de segurança pública.

	Mod.	**Gra.**
Real Mod.	211	40
Real Gra.	18	112

Tabela 3 – MC SVM Baseline Teste

3.2 Random Forest (RF)

O Random Forest apresentou os melhores resultados globais do experimento. Na configuração Baseline, obteve F1-macro de 0,833 na validação cruzada e 0,852 no teste, com acurácia de 0,866, o maior valor registrado entre todas as configurações avaliadas. As Tabelas 4 e 5 resumem os resultados nas quatro variantes.

Config.	**Acc**	**F1**	**Prec**	**Rec**
Baseline	**0,849**	**0,833**	**0,831**	**0,836**
PCA-95%	0,835	0,815	0,818	0,812
PCA-50	0,832	0,810	0,816	0,806
LDA	0,834	0,821	0,815	0,829

Tabela 4 – Random Forest Validação Cruzada

Config.	**Acc**	**F1**	**Prec**	**Rec**
Baseline	**0,866**	**0,852**	**0,850**	**0,856**
PCA-95%	0,861	0,846	0,845	0,846
PCA-50	0,861	0,845	0,846	0,844
LDA	0,835	0,820	0,815	0,826

Tabela 5 – Random Forest Teste

A matriz de confusão do RF Baseline no teste (Tabela 6) mostra 223 verdadeiros negativos e 107 verdadeiros positivos, com apenas 28 falsos positivos e 23 falsos negativos, demonstrando equilíbrio entre precisão e *recall*. Observa-se ainda que a aplicação de LDA reduziu significativamente o desempenho do RF no teste (F1 = 0,820), sugerindo que a projeção para uma única dimensão elimina informações relevantes para o modelo ensemble.

	Mod.	**Gra.**
Real Mod.	223	28
Real Gra.	23	107

Tabela 6 – RF Baseline Teste

3.3 Gradient Boosting (GB)

O Gradient Boosting obteve desempenho comparável ao Random Forest na configuração Baseline, com acurácia de 0,866 e F1-macro de 0,848 no teste. As Tabelas 7 e 8 apresentam os resultados completos.

Config.	**Acc**	**F1**	**Prec**	**Rec**
Baseline	**0,849**	**0,831**	**0,833**	**0,829**
PCA-95%	0,836	0,815	0,822	0,809
PCA-50	0,830	0,808	0,814	0,803
LDA	0,817	0,797	0,796	0,797

Tabela 7 – Gradient Boosting Validação Cruzada

Config.	**Acc**	**F1**	**Prec**	**Rec**
Baseline	**0,866**	**0,848**	**0,857**	0,841
PCA-95%	0,853	0,833	0,841	0,827
PCA-50	0,861	0,845	0,846	**0,844**
LDA	0,840	0,821	0,823	0,819

Tabela 8 – Gradient Boosting Teste

A matriz de confusão do GB Baseline no teste (Tabela 9) revela uma tendência distinta em relação ao RF: o GB apresenta maior precisão para a classe grave (0,832, calculado como $99/(99+20)$), minimizando falsos positivos (20), porém às custas de maior número de falsos negativos (31). Essa característica pode ser relevante em contextos em que classificar erroneamente uma comunidade moderada como grave tenha custo elevado.

	Mod.	Gra.
Real Mod.	231	20
Real Gra.	31	99

Tabela 9 – GB Baseline Teste

3.4 Comparação Global no Conjunto de Teste

A Tabela 10 apresenta a comparação consolidada das 12 configurações ordenadas por F1-macro no conjunto de teste. Os resultados evidenciam dois padrões consistentes: primeiro, a configuração Baseline superou ou igualou as versões com redução de dimensionalidade em praticamente todos os classificadores; segundo, a LDA produziu as piores métricas para RF e GB, confirmando que a compressão para uma única componente é excessivamente restritiva para modelos ensemble que se beneficiam da diversidade de atributos (HASTIE et al., 2009).

A queda de desempenho introduzida pela redução de dimensionalidade é consistente com achados da literatura que indicam que, em conjuntos de dados tabulares com variáveis estruturalmente informativas, a compressão do espaço de características pode descartar variância discriminativa relevante (KUSHWAHA; KUDALE, 2025). No presente caso, as variáveis socioeconômicas originais — em especial aquelas com maior correlação com a variável alvo, como *pctKidsBornNeverMar* ($r = 0{,}61$) e *pctKids2Par* ($r = -0{,}64$) — parecem contribuir de forma aditiva para os classificadores ensemble, tornando a redução de dimensionalidade desnecessária e prejudicial neste contexto.

Tabela 10 – Comparação global das configurações no conjunto de teste, ordenadas por F1-macro

Pré-proc.	**Modelo**	**Acc**	**F1**	**Prec**	**Rec**
Baseline	Random Forest	**0,866**	**0,852**	0,850	**0,856**
Baseline	Gradient Boosting	**0,866**	0,848	**0,857**	0,841
PCA-95%	Random Forest	0,861	0,846	0,845	0,846
PCA-50	Random Forest	0,861	0,845	0,846	0,844
PCA-50	Gradient Boosting	0,861	0,845	0,846	0,844
Baseline	SVM (RBF)	0,848	0,837	0,829	0,851
LDA	SVM (RBF)	0,850	0,837	0,831	0,846
PCA-50	SVM (RBF)	0,845	0,834	0,827	0,849
PCA-95%	Gradient Boosting	0,853	0,833	0,841	0,827
PCA-95%	SVM (RBF)	0,837	0,824	0,818	0,834
LDA	Gradient Boosting	0,840	0,821	0,823	0,819
LDA	Random Forest	0,835	0,820	0,815	0,826

4 Conclusão

Este trabalho investigou o impacto de técnicas de redução de dimensionalidade PCA e LDA sobre o desempenho de três classificadores de aprendizado de máquina (SVM, *Random Forest* e *Gradient Boosting*) na tarefa de classificação binária do nível de violência

comunitária, utilizando o *dataset Communities and Crime Unnormalized* (REDMOND, 2009).

Os resultados obtidos respondem diretamente à questão central proposta: a redução de dimensionalidade **não** melhorou o desempenho dos classificadores neste contexto. Em todas as combinações avaliadas, a configuração *Baseline*, sem qualquer redução, produziu resultados iguais ou superiores às versões com PCA e LDA. A configuração mais eficaz foi o *Random Forest* sem redução de dimensionalidade, com acurácia de 0,866, F1-macro de 0,852, precisão de 0,850 e *recall* de 0,856 no conjunto de teste, resultado consistente com sua capacidade de explorar a diversidade de atributos por meio da amostragem aleatória de variáveis em cada nó de decisão (BREIMAN, 2001).

Com base nesses resultados, recomenda-se o uso do ***Random Forest* na configuração *Baseline*** para a tarefa de classificação do nível de violência comunitária com este conjunto de dados. O modelo apresentou o melhor equilíbrio entre precisão e *recall*,sendo robusto ao desbalanceamento moderado entre as classes por meio do ajuste de pesos inversamente proporcionais à frequência de cada classe. O *Gradient Boosting Baseline* constitui uma alternativa competitiva, especialmente em contextos que demandem maior precisão na identificação da classe grave, dado seu perfil de menor taxa de falsos positivos.

Como limitações do trabalho, destacam-se a dependência de dados censitários norte-americanos de 1990, o que restringe a generalização para outros contextos geográficos e temporais, e a ausência de ajuste fino sistemático dos classificadores, que poderia elevar ainda mais o desempenho das configurações avaliadas. Para trabalhos futuros, sugere-se a investigação de técnicas de seleção de atributos baseadas em importância, como as fornecidas pelo próprio *Random Forest*, como alternativa à redução de dimensionalidade, bem como a aplicação de métodos de balanceamento de classes para tratar o desbalanceamento de forma mais explícita.

Referências

BREIMAN, L. Random forests. *Machine learning*, Springer, v. 45, n. 1, 2001.

CORTES, C.; VAPNIK, V. Support-vector networks. *Machine learning*, Springer, v. 20, n. 3, 1995.

FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. *Annals of statistics*, JSTOR, 2001.

GARCÍA-LAENCINA, P. J.; SANCHO-GÓMEZ, J.-L.; FIGUEIRAS-VIDAL, A. R. Pattern classification with missing data: a review. *Neural Computing and Applications*, Springer, v. 19, n. 2, 2010.

HASTIE, T. et al. *The elements of statistical learning: data mining, inference, and prediction.* [S.l.]: New York: Springer, 2009. v. 2.

JAITMAN, L. et al. *The Costs of Crime and Violence: New Evidence and Insights in Latin America and the Caribbean*. 2017. Disponível em: <https://doi.org/10.18235/0000615>.

JOLLIFFE, I. T. *Principal Component Analysis*. 2. ed. New York: Springer, 2002. (Springer Series in Statistics).

KOHAVI, R. et al. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: MONTREAL, CANADA. *Ijcai*. [S.l.], 1995. v. 14, n. 2.

KUSHWAHA, A. J.; KUDALE, G. J. A comparative study of machine learning algorithms for tabular data classification. *INTERNATIONAL JOURNAL OF ENGINEERING DEVELOPMENT AND RESEARCH*, IJEDR (www. ijedr. org), v. 13, n. 4, 2025.

KYRIAZOS, T.; POGA, M. Application of machine learning models in social sciences: managing nonlinear relationships. *Encyclopedia*, MDPI, v. 4, n. 4, 2024.

MINAYO, M. C. d. S. *Violência e saúde*. 2006. Disponível em: <https://doi.org/10.7476/9788575413807>.

PEDREGOSA, F. et al. Scikit-learn: Machine learning in python. *the Journal of machine Learning research*, JMLR. org, v. 12, p. 2825–2830, 2011.

REDMOND, M. *Communities and Crime Unnormalized*. 2009. UCI Machine Learning Repository. Disponível em: <https://doi.org/10.24432/C5PC8X>.

SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information processing & management*, Elsevier, v. 45, n. 4, 2009.

WEISBURD, D. The law of crime concentration and the criminology of place. *Criminology*, v. 53, n. 2, 2015. Disponível em: <https://onlinelibrary.wiley.com/doi/abs/10.1111/1745-9125.12070>.